UNIVERSIDADE FEDERAL DE VIÇOSA · UFV
CAMPUS FLORESTAL
INSTITUTO DE CIÊNCIAS EXATAS E TECNOLÓGICAS

Trabalho Prático 01 - METAHEURÍSTICA

Professor: Marcus

Gabriel Santos Ferreira de Pádua - 4705

Florestal - MG
2024

Sumário

Sumário **2**
1. Introdução **3**
2. Organização **4**
data/: 4
src/: 5
readme.md 5
3. Desenvolvimento **6**
Soluções iniciais: 6
Critérios de parada: 6
Escolha de vizinhos: 6
Perturbações: 6
Busca Tabu: 6
Simulated Annealing: 7
4. Resultados: **8**
Exemplos Resultados Gráficos: 9
Análise de Boxplots 13
Busca Tabu VS Simulated Annealing 15
Comparação na Função 1 15
Comparação na Função 2 15
5. Conclusão **16**
6. Referências **16**

1. Introdução

A otimização de problemas complexos é um tema central na área de Ciência da Computação, especialmente quando se trata de funções com múltiplos mínimos locais e alta dificuldade de exploração do espaço de busca. Nesse contexto, as meta-heurísticas se destacam como estratégias eficientes para encontrar soluções aproximadas de boa qualidade em problemas onde métodos exatos são inviáveis ou computacionalmente custosos.

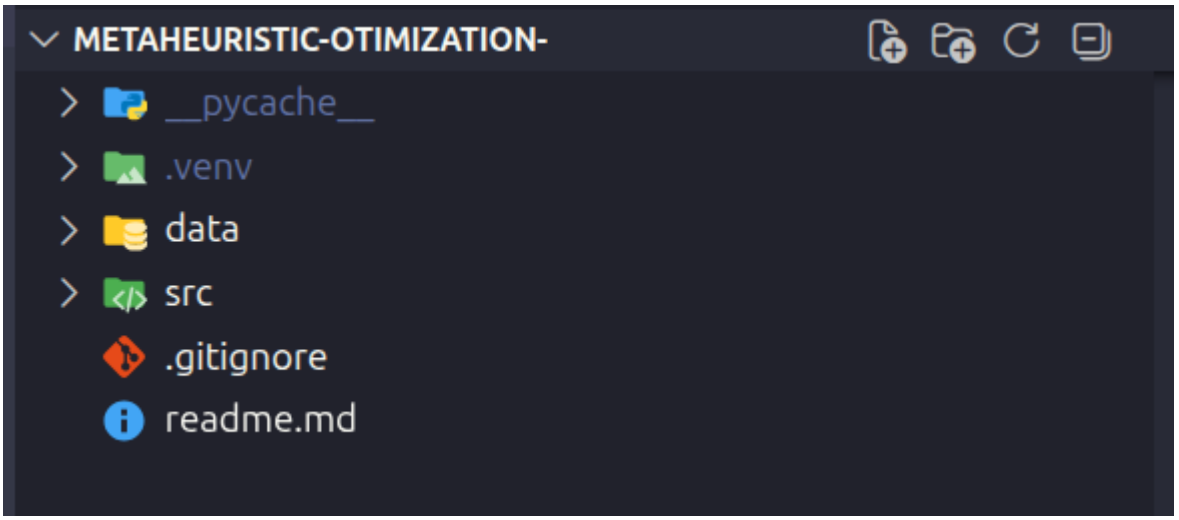
Este trabalho tem como objetivo implementar e analisar o desempenho de algoritmos baseados em metaheurísticas para a minimização de funções objetivo específicas. Em particular, será utilizado o algoritmo de Busca Tabu, juntamente com o algoritmo de Simulated Annealing, permitindo uma comparação entre diferentes abordagens de otimização. As implementações serão avaliadas por meio de múltiplas execuções independentes, possibilitando uma análise estatística dos resultados obtidos.

Além disso, serão considerados diferentes intervalos para as variáveis de decisão, o que influencia diretamente na complexidade do problema e no comportamento dos algoritmos. A análise dos resultados será realizada por meio de métricas como valor mínimo, máximo, média e desvio padrão, bem como por representações gráficas, como boxplots.

Dessa forma, este trabalho busca não apenas aplicar conceitos teóricos estudados na disciplina, mas também proporcionar uma compreensão prática sobre o funcionamento e a eficiência das meta-heurísticas em problemas de otimização.

2. Organização

O projeto foi estruturado com uma organização clara de pastas e arquivos, garantindo que todos os elementos necessários para o completo entendimento e utilização estejam acessíveis.

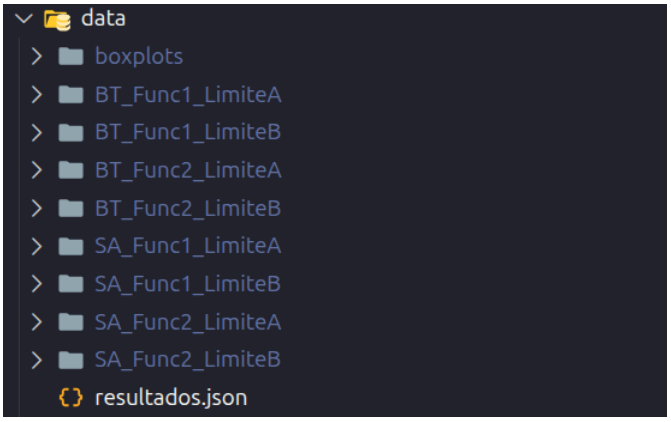


pasta raiz

data/:

Pasta reservada para armazenar resultados e artefatos gerados pelas execuções. Após execução local do script serão gerados os arquivos:

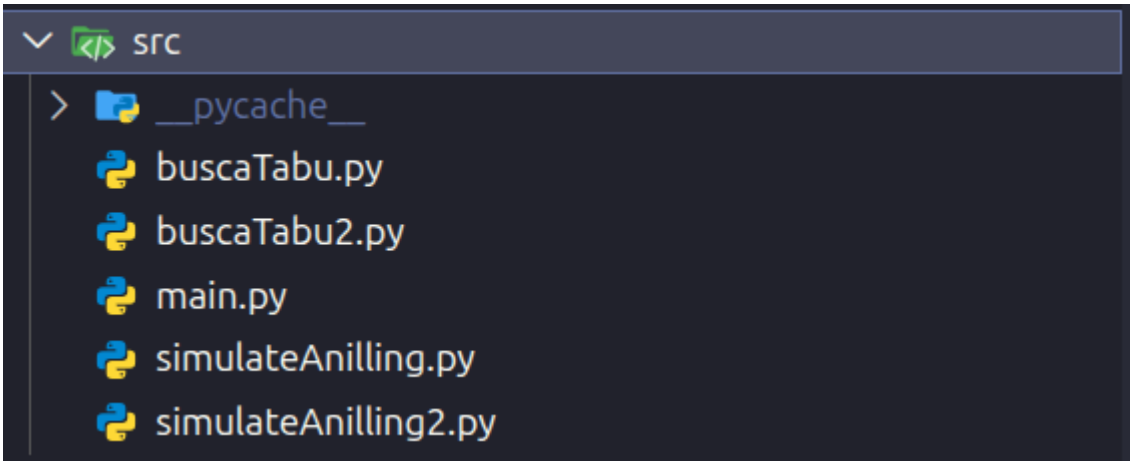
- resultados.json: Consolidação dos resultados das execuções.
- boxplots/: Diretório com Gráficos e dados para boxplots separados por algoritmo, função e limite.
- pastas separadas também por algoritmo, função e limite que contém 30 gráficos cada, de suas representações de execução



src/:

Diretório que guarda arquivos de código-fonte do projeto.

- ***buscaTabu.py*** e ***buscaTabu2.py***: Implementações da Busca Tabu. Onde cada arquivo é responsável pela implementação de uma função objetivo (A ou B).
- ***simulateAnilling.py*** e ***simulateAnilling2.py***: Implementações do Simulated Annealing. Onde cada arquivo é responsável pela implementação de uma função objetivo (A ou B).
- ***main.py***: Ponto de chamada das funções e lógica de repetição.



readme.md

Arquivo de documentação onde pode-se encontrar a visão geral do projeto, instruções de uso e objetivos.

.gitignore

Arquivo de controle para versionamento.

3. Desenvolvimento

Esta seção descreve as principais decisões tomadas durante a implementação das metaheurísticas, com foco em escolhas de inicialização, critérios de parada e configurações específicas de cada algoritmo.

Soluções iniciais:

As soluções iniciais são geradas de forma simples e reprodutível, priorizando a viabilidade e um ponto de partida consistente para comparação entre algoritmos. Para cada iteração das 30 soluções por algoritmo, um conjunto de 30 sementes foram pré setadas, a fim de gerar um “determinismo” ou maneira de replicar, ao mesmo tempo que usufrui-se da aleatoriedade.

Critérios de parada:

O encerramento das execuções ocorre por limite de iterações e, quando aplicável, por estagnação (ausência de melhoria por um número definido de passos).

Escolha de vizinhos:

A geração de vizinhos é baseada em pequenas perturbações na solução atual, preservando a viabilidade e permitindo explorar a vizinhança imediata de forma controlada.

Perturbações:

As perturbações alteram apenas uma pequena parte da solução (por exemplo, ajuste de um elemento, troca local ou variação limitada nos valores), mantendo as restrições do problema. A intensidade da alteração é mantida baixa para explorar incrementos locais, e a seleção dos elementos a modificar é feita de forma simples e aleatória para evitar viés.

Busca Tabu:

- Parâmetros tabu: Movimentos recentes são registrados em uma lista tabu para evitar ciclos. O tamanho da lista controla a memória de curto prazo e impede o retorno imediato a configurações já visitadas.

- Aspiração: Movimentos tabu podem ser aceitos caso resultem em uma melhoria global significativa, evitando bloquear soluções promissoras.

Simulated Annealing:

- Temperatura: A temperatura inicial é definida para permitir uma exploração ampla no início, aceitando pioras controladas para escapar de ótimos locais. O controle é feito através da probabilidade de aceitação de piora.

- Resfriamento: A temperatura é reduzida gradualmente conforme uma taxa de resfriamento, promovendo a transição de exploração para exploração guiada. Foi definida taxa de resfriamento bem baixa, para “ir mais devagar” e evitar rápidas convergências.
- Aceitação: A aceitação de soluções piores segue a probabilidade p = exp(-Delta / T), onde Delta é o aumento no custo e T é a temperatura atual, Quanto maior Delta e menor T, menor a chance de aceitar a piora, sendo assim reduzindo essa permissividade ao longo do tempo.

4. Resultados:

Os experimentos mostraram que foi possível alcançar valores óptimos das funções avaliadas. As metaheurísticas convergiram para soluções de alta qualidade, indicando que as configurações adotadas foram adequadas para explorar o espaço de busca. Embora esteja claro que dentre das 30 sementes geradoras de soluções iniciais, algumas poucas tenham encontrado mais percalços.

Abaixo, alguns exemplos dos gráficos gerados a partir dessas iterações:

Função 1

	Algoritmo	Minimo	Máximo	Média	Desvio-padrão
Domin. A	BT	0,04761600	0,69255900	0,33545200	0,16964500
	SA	0,03011900	0,48550200	0,20486300	0,09252600

	Algoritmo	Minimo	Máximo	Média	Desvio-padrão
Domin. B	BT	0,02592700	0,74394000	0,34345700	0,16511000
	SA	0,02914200	0,47703500	0,19120000	0,11008500

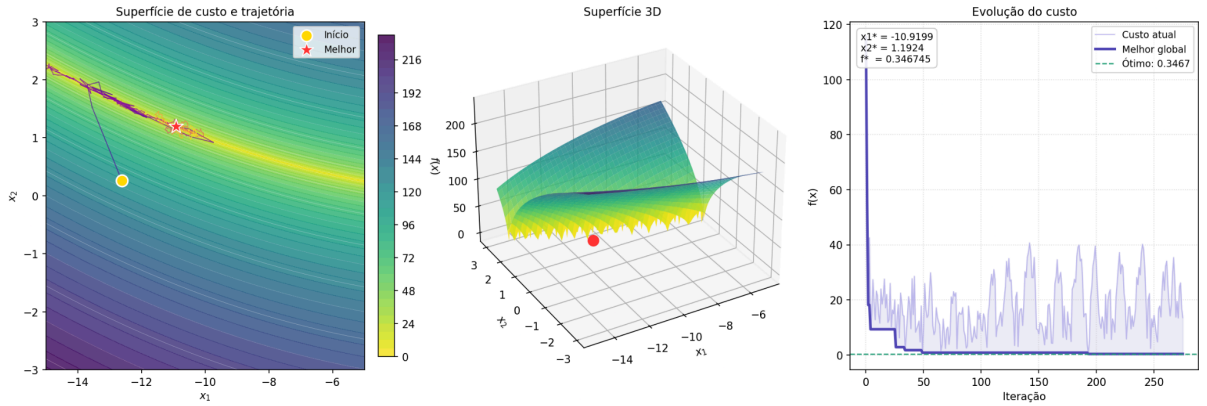
Função 2

	Algoritmo	Minimo	Máximo	Média	Desvio-padrão
Domin. A	BT	-1,80130300	-1,08748500	-1,69920400	0,22922000
	SA	-1,80129400	-1,80046000	-1,80113500	0,00017800

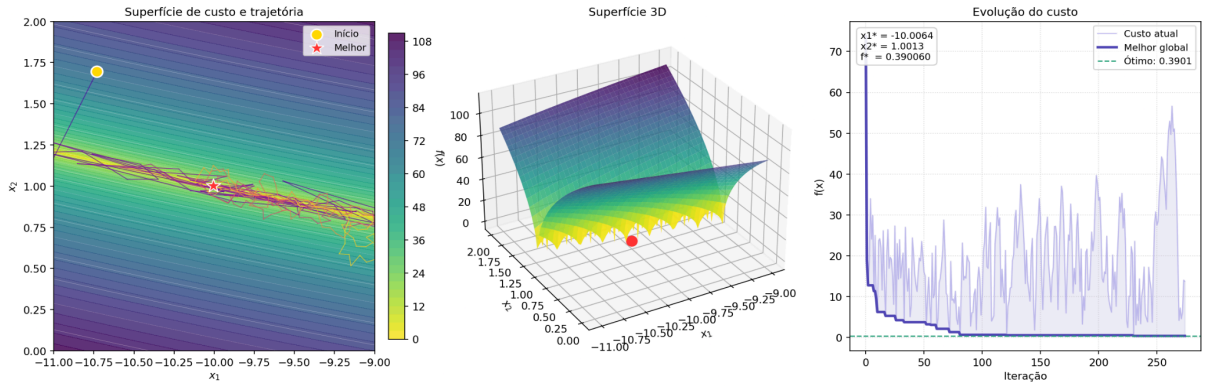
	Algoritmo	Minimo	Máximo	Média	Desvio-padrão
Domin. B	BT	-1,80130300	-1,80126200	-1,80129600	0,00001000
	SA	-1,80130200	-1,80065300	-1,80117200	0,00015100

Exemplos Resultados Gráficos:

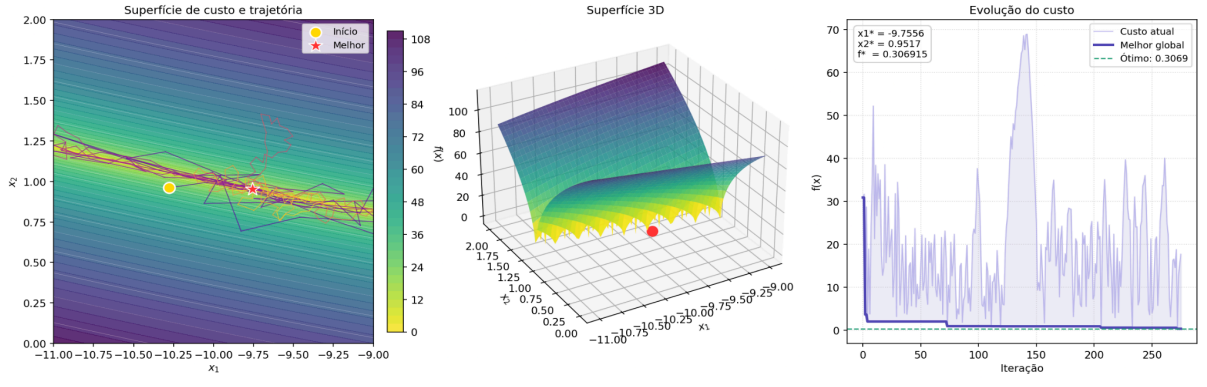
Busca Tabu — $f(x_1, x_2) = 100\sqrt{|x_2 - 0.01\,x_1^2|} + 0.01\,|x_1 + 10|$



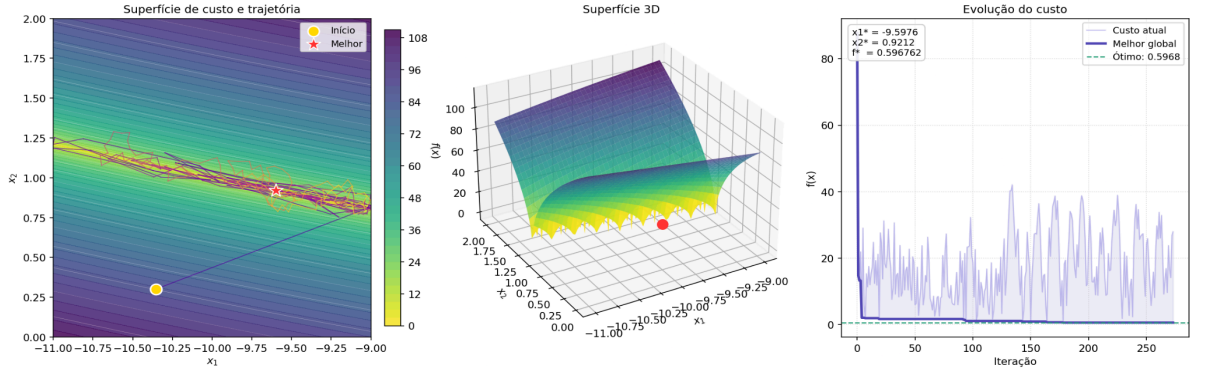
Busca Tabu — $f(x_1, x_2) = 100\sqrt{|x_2 - 0.01\,x_1^2|} + 0.01\,|x_1 + 10|$



Busca Tabu — $f(x_1, x_2) = 100\sqrt{|x_2 - 0.01\,x_1^2|} + 0.01\,|x_1 + 10|$

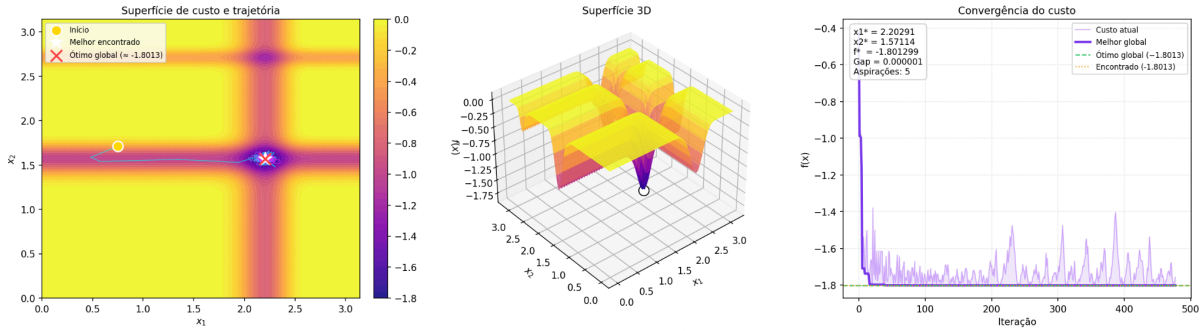


Busca Tabu — $f(x_1, x_2) = 100\sqrt{|x_2 - 0.01\,x_1^2|} + 0.01\,|x_1 + 10|$



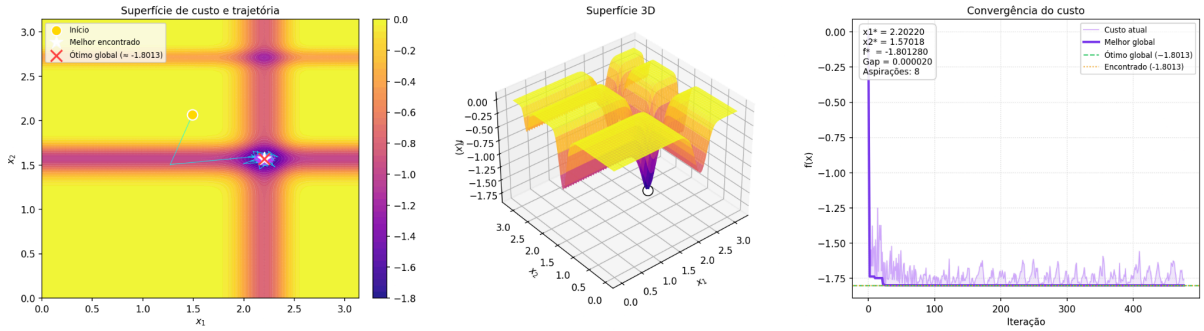
Busca Tabu — Função de Michalewicz $f(\mathbf{x}) = -\sum_{i=1}^{d} \sin(x_i)\sin^{2m}\left(\frac{ix_i^2}{\pi}\right)$

$d = 2,\ m = 10,\ 0 \le x_1, x_2 \le \pi$



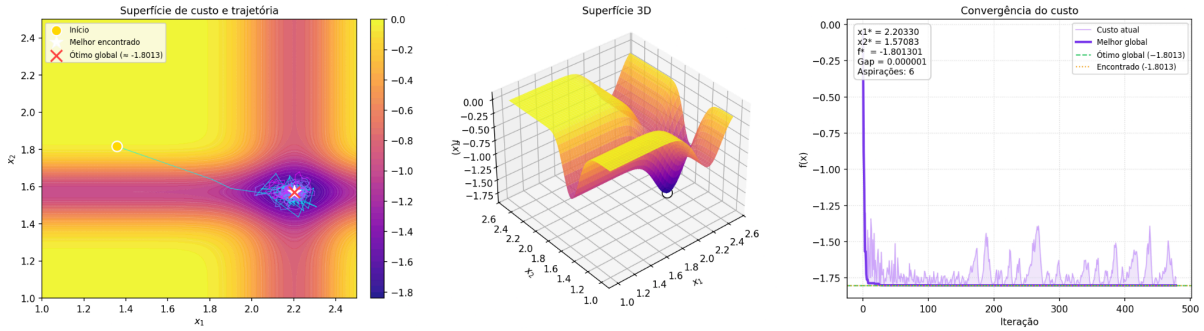
Busca Tabu — Função de Michalewicz $f(\mathbf{x}) = -\sum_{i=1}^{d} \sin(x_i)\sin^{2m}\left(\frac{ix_i^2}{\pi}\right)$

$d = 2,\ m = 10,\ 0 \le x_1, x_2 \le \pi$



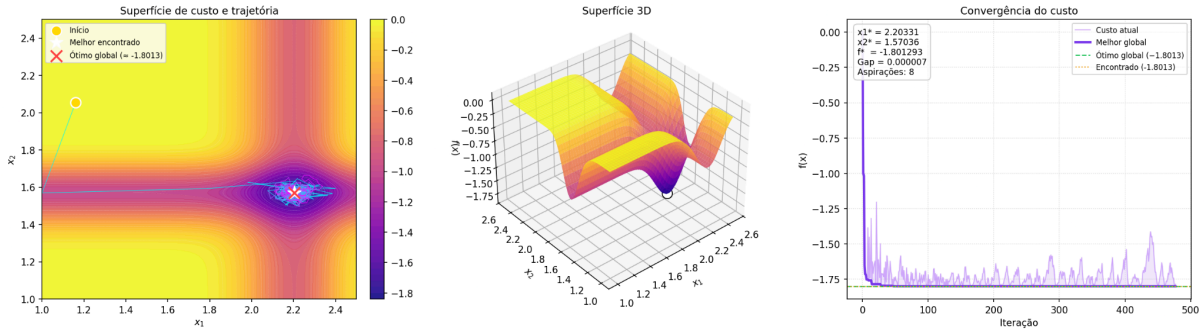
Busca Tabu — Função de Michalewicz $f(\mathbf{x}) = -\sum_{i=1}^{d} \sin(x_i)\sin^{2m}\left(\frac{ix_i^2}{\pi}\right)$

$d = 2,\ m = 10,\ 0 \le x_1, x_2 \le \pi$

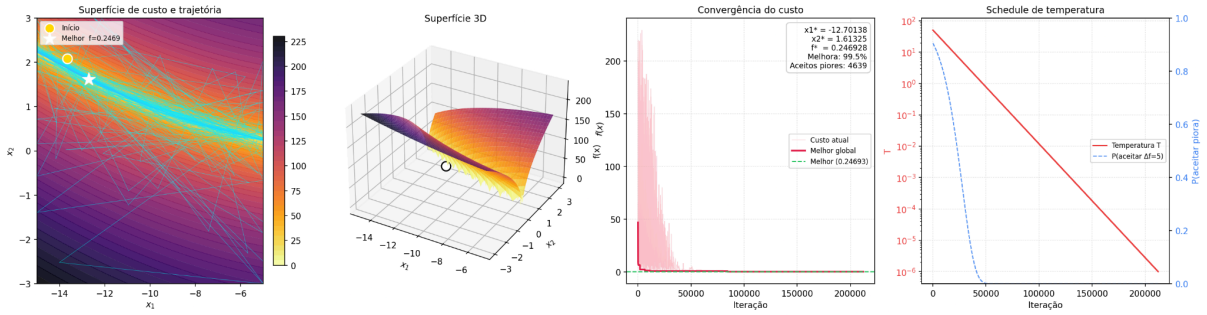


Busca Tabu — Função de Michalewicz $f(\mathbf{x}) = -\sum_{i=1}^{d} \sin(x_i)\sin^{2m}\left(\frac{ix_i^2}{\pi}\right)$

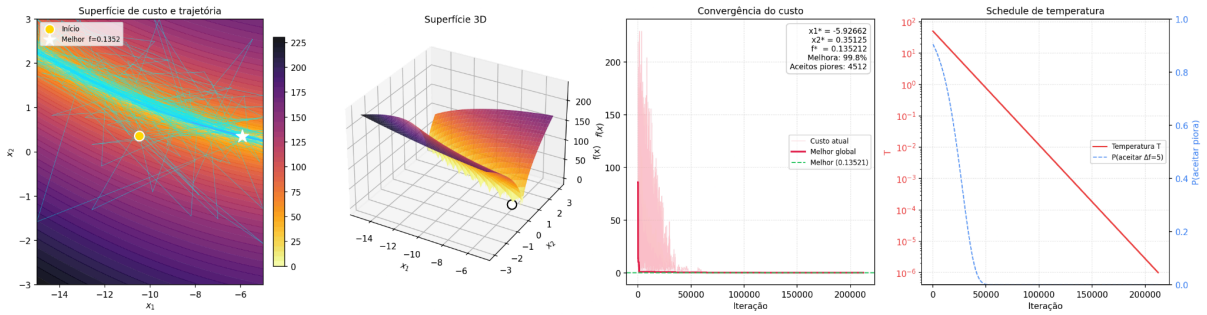
$d = 2,\ m = 10,\ 0 \le x_1, x_2 \le \pi$



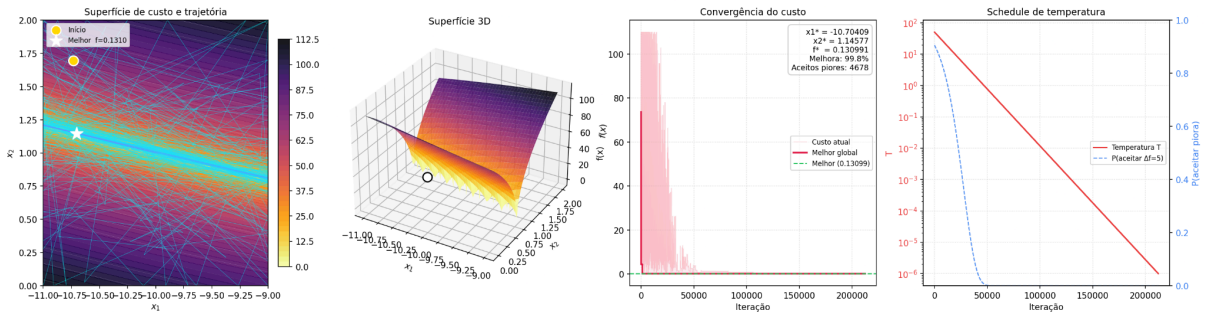
Simulated Annealing — $f(x_1, x_2) = 100\sqrt{|x_2 - 0.01\,x_1^2|} + 0.01\,|x_1 + 10|$
$-15 \le x_1 \le -5, \quad -3 \le x_2 \le 3$



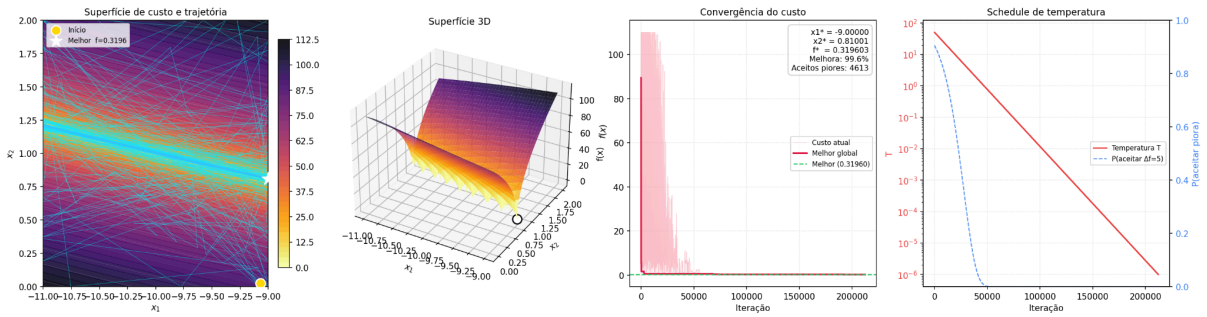
Simulated Annealing — $f(x_1, x_2) = 100\sqrt{|x_2 - 0.01\,x_1^2|} + 0.01\,|x_1 + 10|$
$-15 \le x_1 \le -5, \quad -3 \le x_2 \le 3$



Simulated Annealing — $f(x_1, x_2) = 100\sqrt{|x_2 - 0.01\,x_1^2|} + 0.01\,|x_1 + 10|$
$-15 \le x_1 \le -5, \quad -3 \le x_2 \le 3$

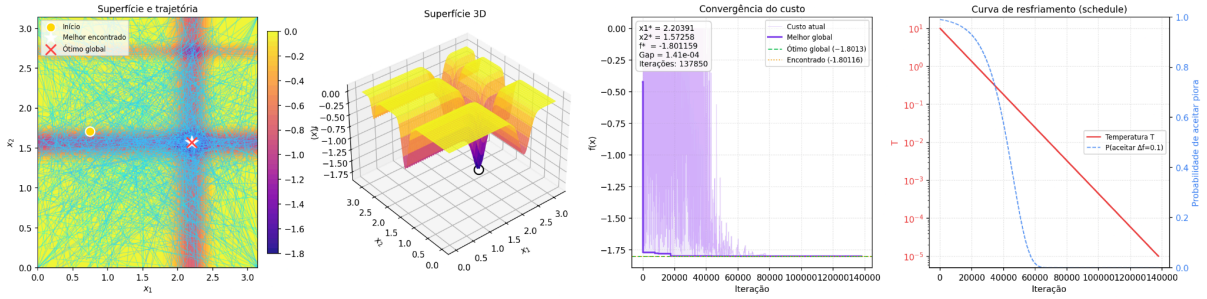


Simulated Annealing — $f(x_1, x_2) = 100\sqrt{|x_2 - 0.01\,x_1^2|} + 0.01\,|x_1 + 10|$
$-15 \le x_1 \le -5, \quad -3 \le x_2 \le 3$



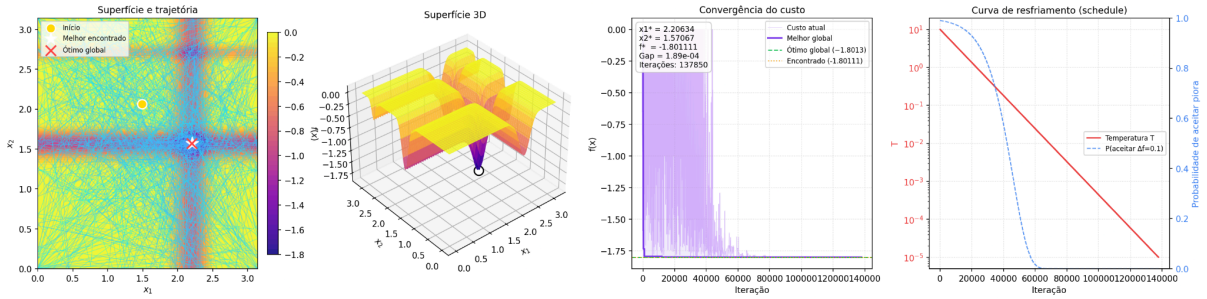
Simulated Annealing — Função de Michalewicz

$$f(\mathbf{x}) = -\sum_{i=1}^{d} \sin(x_i)\sin^{2m}\left(\frac{ix_i^2}{\pi}\right) \quad d=2,\ m=10,\ 0.0 \le x_1, x_2 \le 3.141592653589793$$



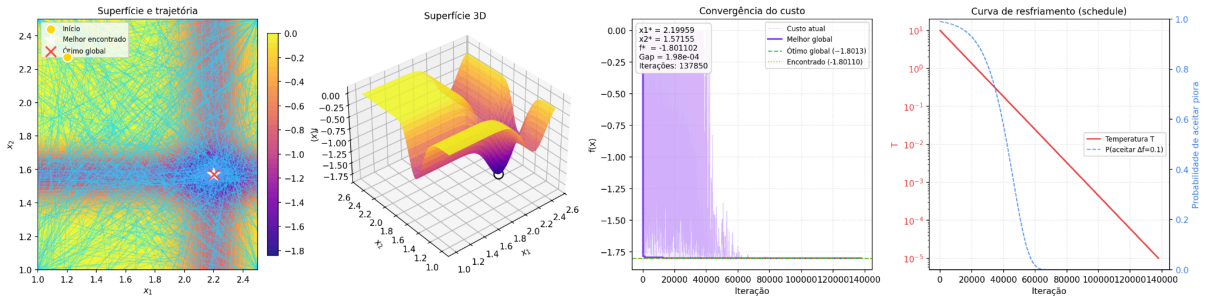
Simulated Annealing — Função de Michalewicz

$$f(\mathbf{x}) = -\sum_{i=1}^{d} \sin(x_i)\sin^{2m}\left(\frac{ix_i^2}{\pi}\right) \quad d=2,\ m=10,\ 0.0 \le x_1, x_2 \le 3.141592653589793$$



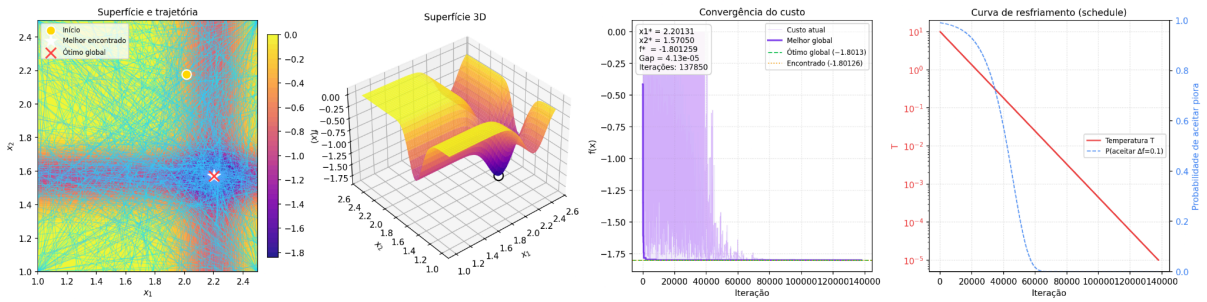
Simulated Annealing — Função de Michalewicz

$$f(\mathbf{x}) = -\sum_{i=1}^{d} \sin(x_i)\sin^{2m}\left(\frac{ix_i^2}{\pi}\right) \quad d=2,\ m=10,\ 1.0 \le x_1, x_2 \le 2.5$$

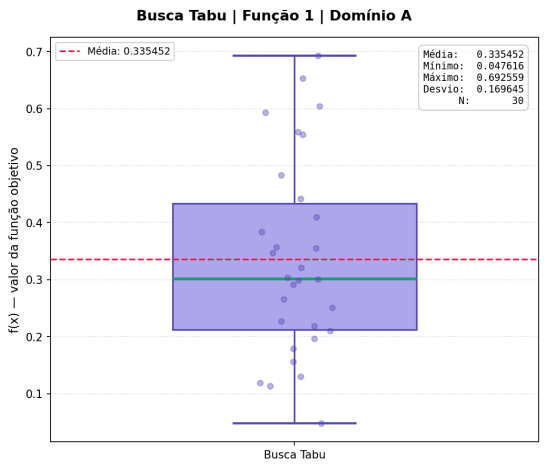


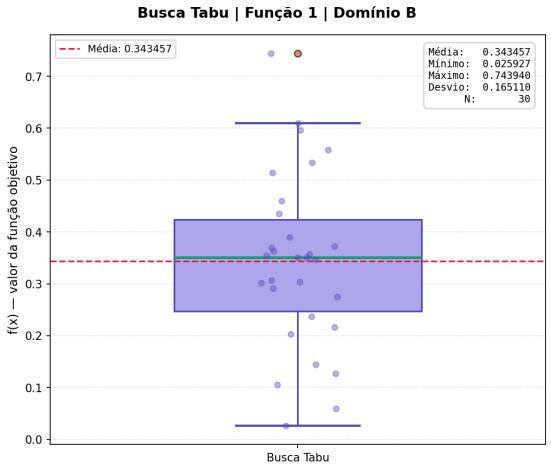
Simulated Annealing — Função de Michalewicz

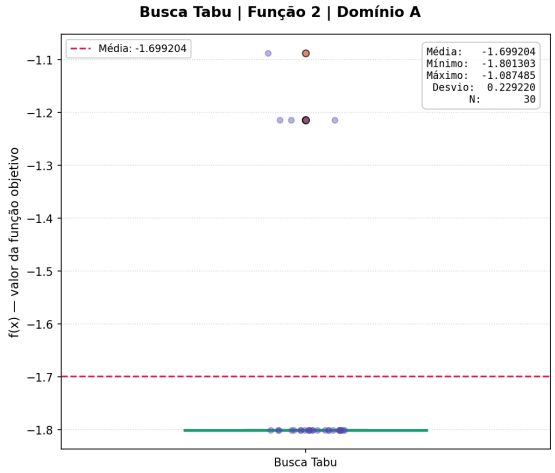
$$f(\mathbf{x}) = -\sum_{i=1}^{d} \sin(x_i)\sin^{2m}\left(\frac{ix_i^2}{\pi}\right) \quad d=2,\ m=10,\ 1.0 \le x_1, x_2 \le 2.5$$

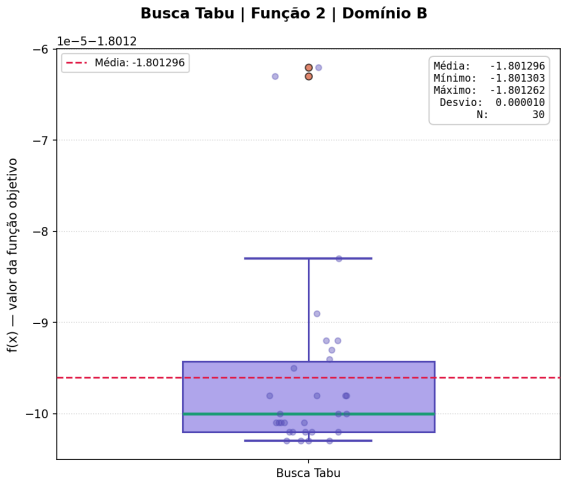


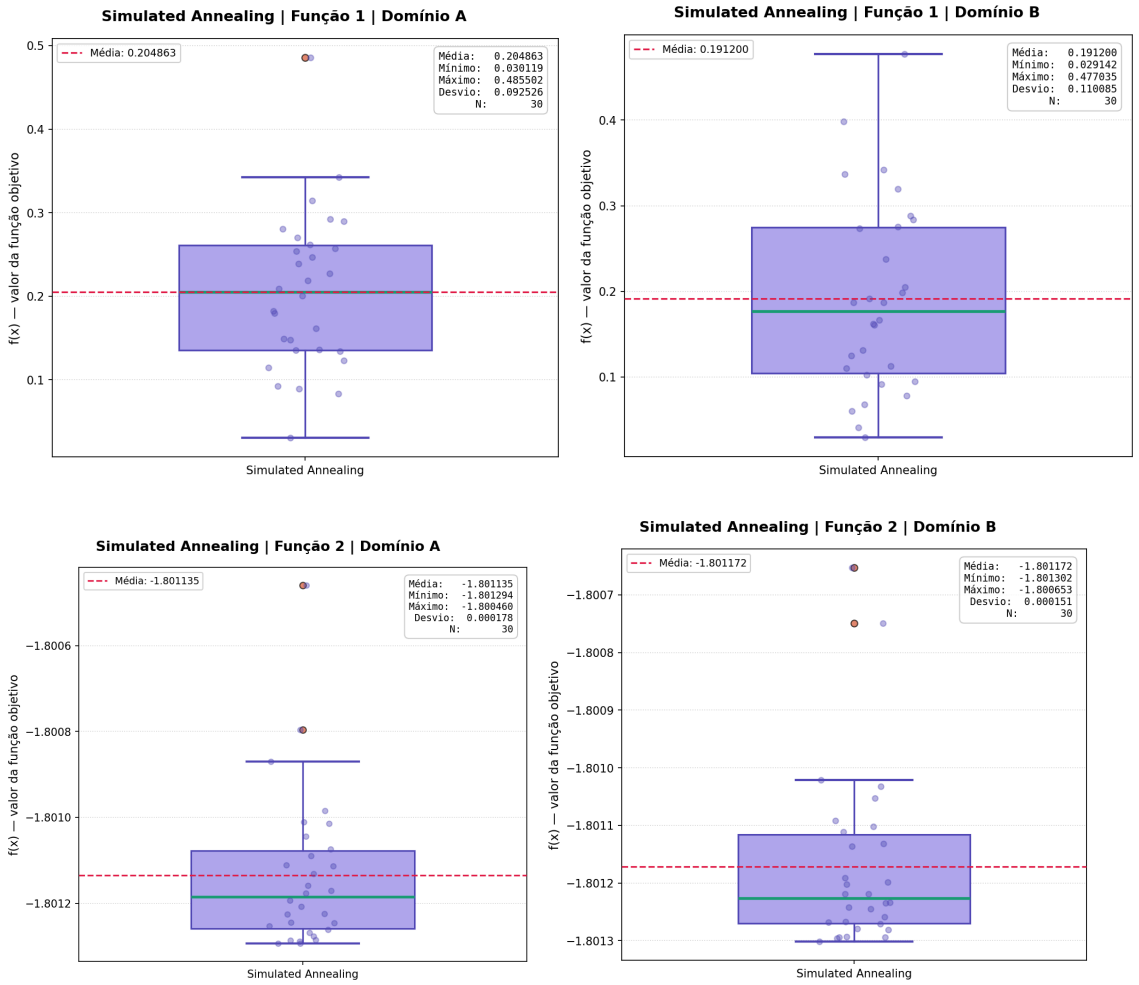
Análise de Boxplots











Função 1:

- **BT-Domínio A:** Apresenta alta dispersão (Desvio: 0.169). A média (0.335) está próxima da mediana, mas os resultados estão espalhados por quase todo o range observado.
- **BT-Domínio B:** Comportamento similar ao Domínio A, com média levemente superior (0.343) e dispersão ainda alta. O boxplot é "alto", indicando falta de consistência entre as 30 execuções.
- **SA-Domínio A:** Resultado muito mais consistente. A média (0.204) é significativamente menor que a do BT. O boxplot é mais achatado, indicando que a maioria das soluções convergiu para valores baixos, apesar de um *outlier* superior próximo a 0.5.
- **SA-Domínio B:** Melhor performance para a F1. Média de 0.191 e um desvio padrão de 0.110. A concentração de dados no primeiro quartil mostra que o algoritmo frequentemente encontra valores próximos ao mínimo global.

Função 2:

- **BT-Domínio A:** Apresenta um comportamento curioso. Embora a maioria dos pontos esteja concentrada em -1.80, a média (-1.699) é puxada para cima por diversos pontos de falha (entre -1.1 e -1.3). Isso indica que o BT ficou "preso" em ótimos locais ruins em várias das 30 execuções.
- **BT-Domínio B: Performance excepcional.** O desvio padrão é quase zero (0.000010). O algoritmo foi extremamente estável, convergindo para -1.8013 em praticamente todas as rodadas.
- **SA-Domínio A:** Muito estável, com média de -1.8011. Apresenta dois *outliers* claros, mas a caixa (50% dos dados) é muito estreita, mostrando boa precisão.
- **SA-Domínio B:** Comportamento idêntico ao Domínio A, com média de -1.8011. É um algoritmo muito confiável para esta função.

Busca Tabu VS Simulated Annealing

Ao comparar as duas meta-heurísticas, observamos comportamentos distintos dependendo da complexidade da função:

Comparação na Função 1

O melhor mostrou ser o simulador annealing (SA), já que demonstrou uma capacidade de convergência muito superior. Enquanto o BT espalhou seus resultados (indicando que a busca tabu pode ter tido dificuldade em explorar o espaço de estados de forma eficiente ou a lista tabu não foi suficiente para evitar ciclos improdutivos), o SA manteve médias e medianas muito mais baixas.

A dispersão (amplitude do boxplot) do BT é quase o dobro da do SA, o que torna o SA uma escolha mais "segura" e robusta para a função 1.

Comparação na Função 2

Na função 2, quem se mostrou melhor foi a Busca Tabu (BT).No Domínio B atingiu um nível de precisão cirúrgica, superando o SA em termos de desvio padrão. Embora seja bom lembrar que em confiabilidade o SA se mostrou mais resiliente (confiável), já que no Domínio A, o BT falhou em várias execuções (puxando a média para -1.69), enquanto o SA manteve-se firme em -1.80 em ambos os domínios.

Em termos gerais, se a estabilidade absoluta é necessária e o domínio é favorável, o BT (Dom B) é impecável. Se houver incerteza sobre o domínio, o SA oferece um resultado médio melhor por não apresentar as falhas graves que o BT mostrou no Domínio A.

5. Conclusão

De forma geral, os algoritmos apresentaram desempenhos consistentes, com diferenças de velocidade de convergência e sensibilidade aos parâmetros. A Busca Tabu tende a estabilizar rapidamente ao evitar ciclos, enquanto o Simulated Annealing oferece maior flexibilidade inicial por aceitar pioras controladas. A comparação reforça que ambas as abordagens são eficazes, e a escolha entre elas depende do equilíbrio desejado entre exploração e intensificação.

6. Referências

- Slides - Professor Marcus - UFV
- https://www.ime.usp.br/~gold/cursos/2009/mac5758/AndreBuscaTabu.pdf
- https://sites.icmc.usp.br/sandra/G9_t2/annealing.htm