UNIVERSIDADE FEDERAL DE VIÇOSA · UFV
CAMPUS FLORESTAL
INSTITUTO DE CIÊNCIAS EXATAS E TECNOLÓGICAS

Trabalho Prático 03 - META-HEURÍSTICA

Professor: Marcus

Gabriel Santos Ferreira de Pádua - 4705

Florestal - MG
2024

Sumário

Sumário **2**
1. Introdução **3**
2. Organização **4**
Data/: 4
Ant_System/ 5
README.md 5
3. Desenvolvimento **6**
Arquivo de Memória (K): 6
Ranqueamento: 6
Limite de Iterações: 6
Convergência Estrutural (Exploração vs. Explotação): 6
Limites de Domínio (Clipping): 6
Conversão de Igualdades: 7
Penalidade Estática: 7
Regulação de Evaporação 7
4. Resultados: **8**
Análise de Boxplots 10
Análise no Algoritmo do TP1 (Otimização Contínua sem Restrições) 10
Análise no Algoritmo do TP2 (Otimização Contínua com Restrições) 10
5. Conclusão **11**
6. Referências **12**

1. Introdução

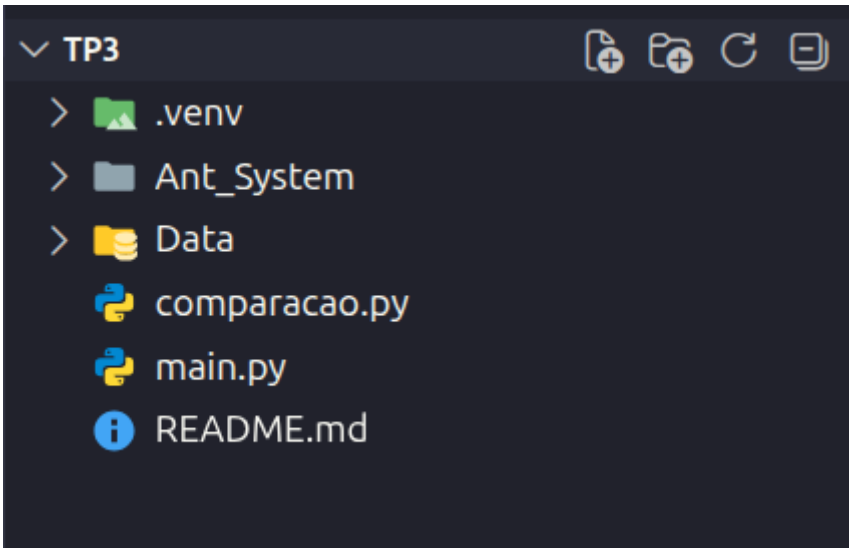
A resolução de problemas complexos de otimização é um desafio central na Ciência da Computação, especialmente quando o espaço de busca apresenta alta dimensionalidade, não linearidade e a presença de restrições severas. Nesses cenários, os métodos exatos baseados em cálculo diferencial tornam-se frequentemente computacionalmente proibitivos, justificando a aplicação de meta-heurísticas. Dentre essas abordagens, destacam-se os algoritmos baseados em Inteligência Coletiva (Swarm Intelligence), que modelam o comportamento cooperativo, descentralizado e auto-organizado de agentes biológicos para explorar o espaço de soluções de forma eficiente e robusta.

O presente trabalho tem como objetivo principal implementar e analisar o desempenho de um algoritmo baseado em Inteligência Coletiva cooperativa na resolução de dois cenários distintos de otimização contínua..

Será possível compreender o comportamento empírico, a robustez e as limitações de cada algoritmo frente a diferentes relevos matemáticos. O Teorema do No Free Lunch (Não Existe Almoço Grátis) postula que nenhuma técnica de otimização é universalmente superior para todas as classes de problemas, o que torna a investigação comparativa uma etapa indispensável no desenvolvimento de sistemas computacionais otimizados e para garantir o rigor estatístico da análise comparativa, o algoritmo cooperativo será submetido a 30 execuções independentes em cada cenário. Os resultados obtidos permitirão a extração de métricas de consistência, englobando o valor mínimo, máximo, média e desvio padrão da função objetivo, além da elaboração de representações visuais através de boxplots. Por fim, o trabalho discutirá comparativamente o comportamento da abordagem populacional em relação aos métodos testados nos trabalhos práticos anteriores

2. Organização

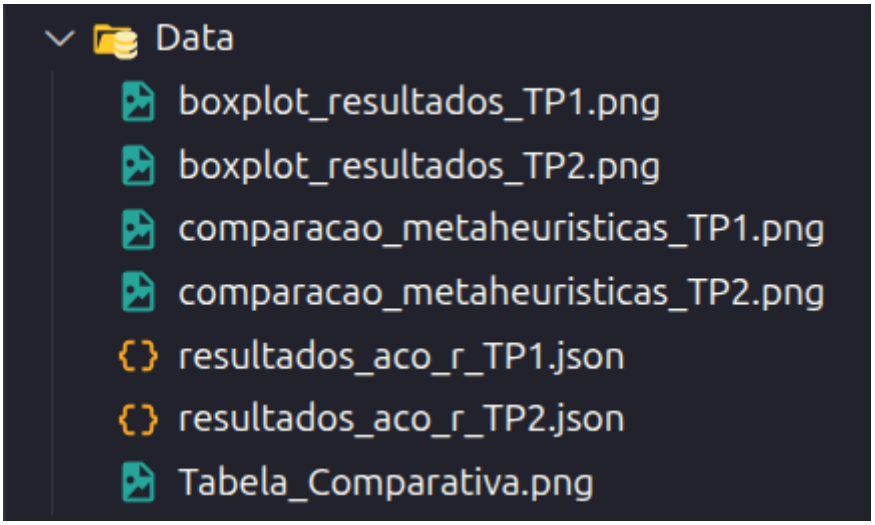
O projeto foi estruturado com uma organização clara de pastas e arquivos, garantindo que todos os elementos necessários para o completo entendimento e utilização estejam acessíveis.



pasta raiz

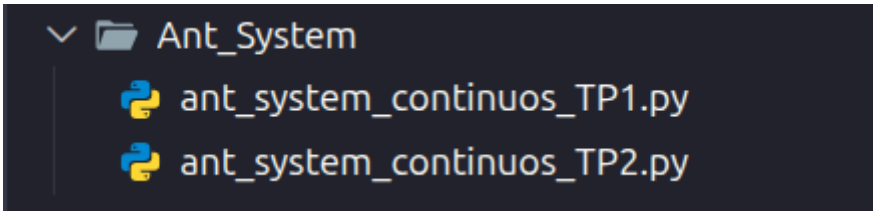
Data/:

Pasta reservada para armazenar resultados e artefatos gerados pelas execuções. Após execução local do script serão gerados os arquivos:



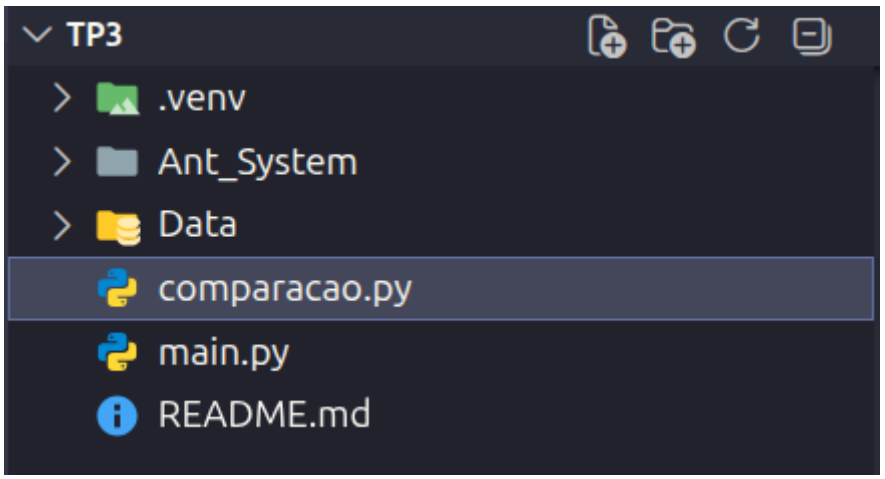
Ant_System/

Diretório responsável de armazenar os códigos do algoritmo de colônia de formigas, de maneira a serem modulares.



comparacao.py

Algoritmo que compara as funções de todos as meta heurísticas envolvidas e plota um gráfico para cada problema.



README.md

Arquivo de documentação onde pode-se encontrar instruções de execução e configuração de ambiente.

3. Desenvolvimento

Esta seção descreve as principais decisões tomadas durante a implementação do foco em escolhas de inicialização e configurações específicas do algoritmo de colônia de formigas.

Arquivo de Memória (K):

A população inicial não gera caminhos vazios, mas sim um "Arquivo de Soluções" contendo K posições geradas aleatoriamente dentro dos limites do domínio do problema.

Ranqueamento:

Essas soluções iniciais são imediatamente avaliadas pela função objetivo e ordenadas da melhor para a pior. Este arquivo atua como a base de "feromônio" inicial: as soluções no topo da lista ganham pesos maiores probabilísticos para servirem de "guia" para as próximas formigas.

Limite de Iterações:

O critério de parada principal adotado foi um número fixo de iterações ou de avaliações da função objetivo.

Convergência Estrutural (Exploração vs. Explotação):

O algoritmo possui uma regulação intrínseca de parada baseada no desvio padrão (σ). No início, com soluções espalhadas, o σ é grande (ampla exploração). Conforme o limite de iterações se aproxima e o arquivo de soluções converge para um vale promissor (por exemplo, buscando o mínimo ao redor de x1 = -10.0 e x2=1.0), o σ encolhe drasticamente, limitando as formigas a um refinamento milimétrico final.

Limites de Domínio (Clipping):

Durante o passo de geração de novos valores contínuos via distribuição Gaussiana, o algoritmo pode sugerir pontos fora do espaço amostral. Para contornar isso, aplicou-se uma função de limite rigoroso para garantir que nenhuma variável assumisse valores inválidos que pudessem quebrar a matemática da função (como raízes de números negativos).

Conversão de Igualdades:

Para restrições de igualdade estritas presentes no problema, utilizou-se uma margem de tolerância ε (ex: 0.0001), transformando-as em restrições de desigualdade flexíveis para permitir a factibilidade computacional.

Penalidade Estática:

Para lidar com as restrições complexas do espaço de busca (especialmente no TP2), optou-se pela aplicação de Penalidades Severas na Função Objetivo. Qualquer formiga que gerasse uma solução violando as restrições matemáticas recebia um acréscimo gigantesco no valor final da função. Isso atuava de forma pedagógica na colônia, "secando o feromônio" daquela região e forçando o enxame a buscar o ótimo apenas dentro do espaço factível.

Regulação de Evaporação

A taxa de convergência da colônia foi regulada pelo parâmetro ξ(xi). Ele atua como um análogo à taxa de evaporação de feromônio do modelo discreto, ponderando o cálculo das distâncias entre a formiga guia e o restante do arquivo, o que dita a velocidade com que o algoritmo abandona regiões ruins e foca na melhor área encontrada.

4. Resultados:

Função 1(A) - TP1				
ALGORITIMOS	Minimo	Máximo	Média	Desvio-padrão
Ant Community	0,26687777	4,21036619	1,70220234	1,04581103
Busca Tabu	0,04761600	0,69255900	0,33545200	0,16964500
Simulate Anilling	0,03011900	0,48550200	0,20486300	0,09252600

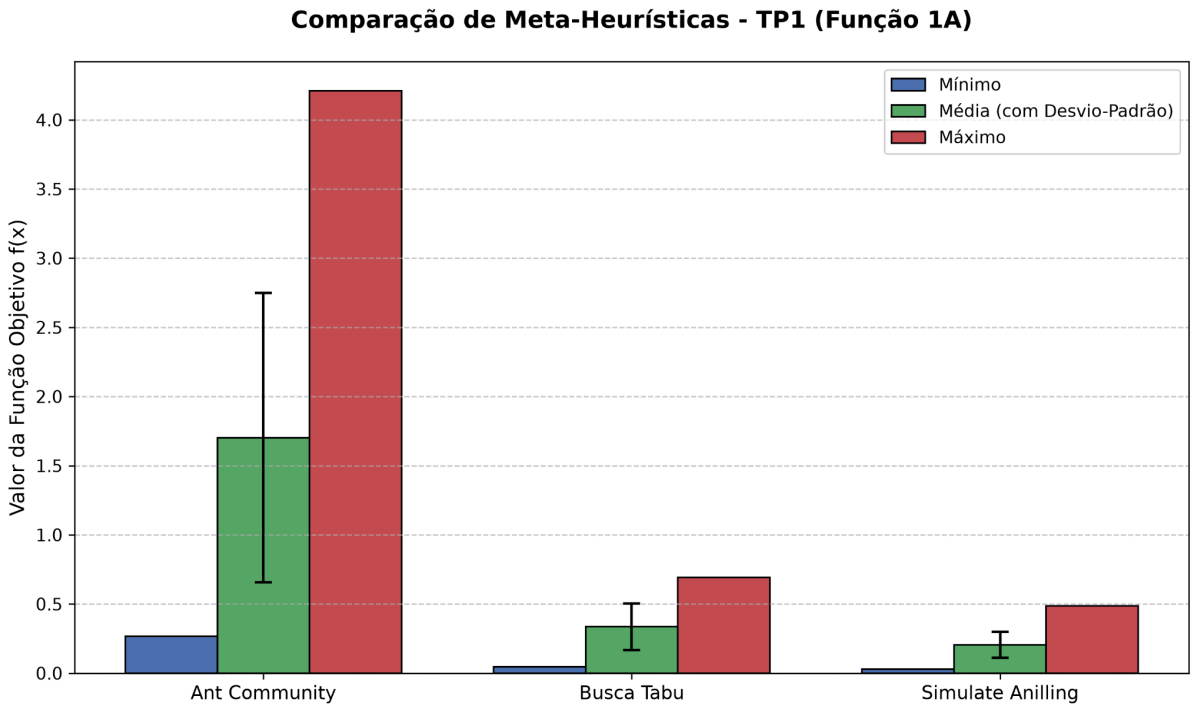
Função 1 - TP2				
ALGORITIMOS	Minimo	Máximo	Média	Desvio-padrão
Ant Community	-3,84173156	-0,00013778	-0,50107793	0,96709178
Rest. Penalidade Estatica	-3,88793589	-0,00008640	-2,24277731	1,02822357
Rest. Stochastic Ranking	-3,34352677	-0,00006892	-0,61388757	0,84161949

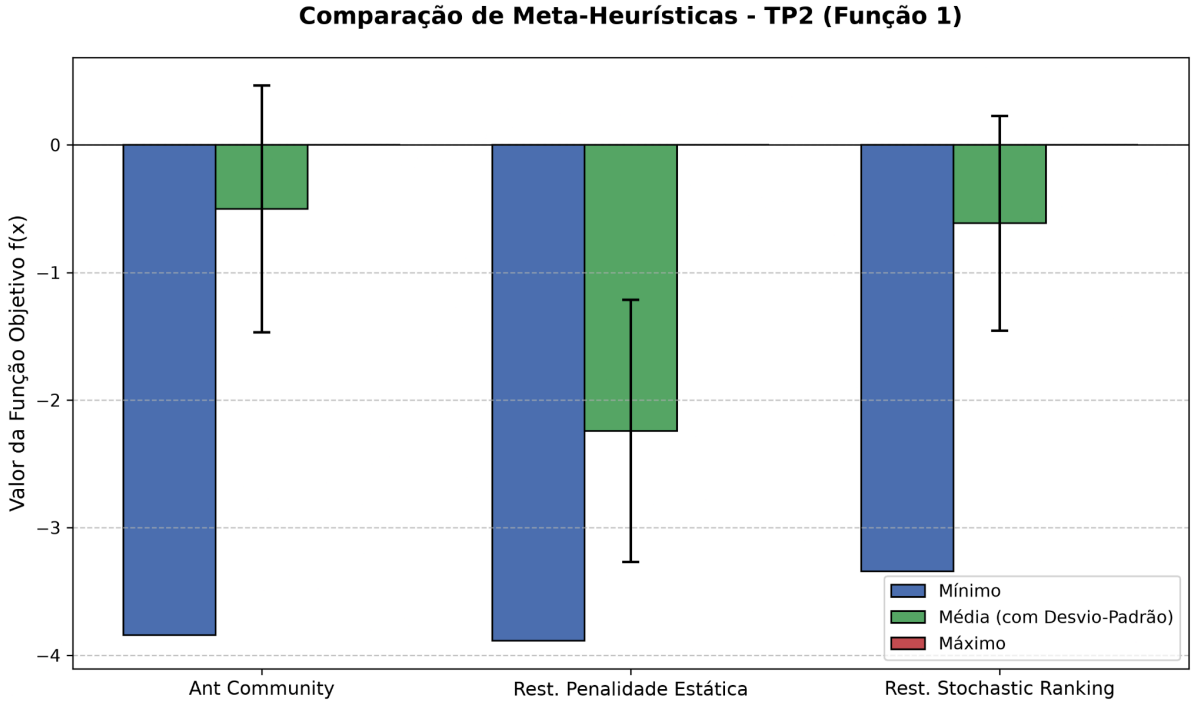
Para uma melhor visualização, a tabela de baixo apresenta cores, embora seja igual em valores a tabela de cima.

Função 1(A) - TP1				
ALGORITIMOS	Minimo	Máximo	Média	Desvio-padrão
Ant Community	0,26687777	4,21036619	1,70220234	1,04581103
Busca Tabu	0,04761600	0,69255900	0,33545200	0,16964500
Simulate Anilling	0,03011900	0,48550200	0,20486300	0,09252600

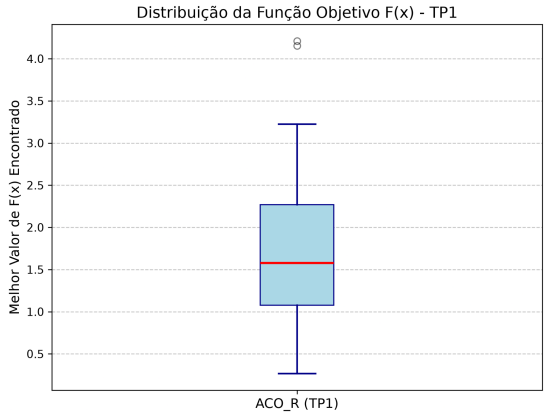
Função 1 - TP2				
ALGORITIMOS	Minimo	Máximo	Média	Desvio-padrão
Ant Community	-3,84173156	-0,00013778	-0,50107793	0,96709178
Rest. Penalidade Estatica	-3,88793589	-0,00008640	-2,24277731	1,02822357
Rest. Stochastic Ranking	-3,34352677	-0,00006892	-0,61388757	0,84161949

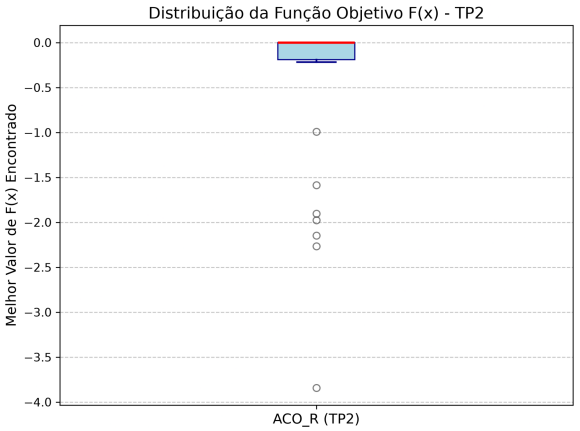
META-HEURISTICAS OPTIMIZATION
COMUNIDADE
EVOLUTIVOS


Comparação de Meta-Heurísticas - TP1 (Função 1A)
Mínimo
Média (com Desvio-Padrão)
Máximo
Valor da Função Objetivo f(x)
4.0
3.5
3.0
2.5
2.0
1.5
1.0
0.5
0.0
Ant Community
Busca Tabu
Simulate Anilling


Comparação de Meta-Heurísticas - TP2 (Função 1)
Valor da Função Objetivo f(x)
0
−1
−2
−3
−4
Mínimo
Média (com Desvio-Padrão)
Máximo
Ant Community
Rest. Penalidade Estática
Rest. Stochastic Ranking

Análise de Boxplots





Análise no Algoritmo do TP1 (Otimização Contínua sem Restrições)

Domínio do Simulated Annealing (SA): O SA foi o vencedor absoluto. Ele não só encontrou o menor mínimo global (0.030), como tem a menor média (0.204) e o menor desvio-padrão (0.092). Isso indica que ele é extremamente robusto. Em quase todas as 30 rodadas, ele "desceu a ladeira" direto para o fundo do vale de forma consistente. A Busca Tabu acompanhou de perto, confirmando que métodos de *trajetória* são matadores nesse tipo de superfície.

A Dificuldade do Ant Community: O ACO_R teve um desempenho bem inferior. O desvio-padrão gigante (maior que a própria variação de muitos dos outros métodos) mostra que a colônia de formigas está se perdendo no espaço de busca. Em algumas rodadas, elas convergem para um ótimo local ruim e a Gaussiana "encolhe" muito rápido (convergência prematura), travando o algoritmo num valor alto (máximo de 4.21).

Análise no Algoritmo do TP2 (Otimização Contínua com Restrições)

A Força da Penalidade Estática: Nos métodos evolutivos, a Restrição por Penalidade Estática dominou a média (-2.24) e encontrou o melhor mínimo absoluto (-3.88). A aplicação de penalidades severas ajudou o algoritmo a "quicar" para fora das zonas proibidas e explorar o vale correto.

Ant Community: O ACO teve um comportamento muito interessante aqui. Ele encontrou um mínimo excelente (-3.84), que está "encostado" no melhor valor da Penalidade Estática. No entanto, a média dele foi horrível (-0.50).

Na prática, isso significa que o ACO tem capacidade exploratória para achar o ótimo global, mas ele não tem repetibilidade. Ele acertou o alvo numa rodada de muita sorte, mas na maioria das outras execuções, a colônia de formigas não conseguiu contornar o relevo acidentado criado pelas restrições do Método das Penalidades, ficando presa em médias ruins.

5. Conclusão

O desenvolvimento e a execução dos experimentos cumpriram com êxito o objetivo proposto, demonstrando que todos os algoritmos implementados foram capazes de convergir e obter valores válidos e factíveis em todos os casos testados. Apesar da eficácia geral na obtenção de soluções viáveis, a análise estatística dos resultados evidenciou diferenças significativas no comportamento de busca e na eficiência de cada método, fortemente influenciadas pela topologia do problema.

Em suma, os resultados obtidos confirmam a validade algorítmica e matemática de todas as meta-heurísticas testadas para a resolução dos problemas práticos propostos. A diferença prática entre elas não reside na capacidade de encontrar uma solução, mas sim na forma como a natureza de cada algoritmo (trajetória vs. populacional) reage à complexidade e às restrições do espaço de busca.

6. Referências

- Slides - Professor Marcus - UFV
- https://pt.wikipedia.org/wiki/Col%C3%B4nia_de_formigas_(otimiza%C3%A7%C3%A3o)
- https://www.cin.ufpe.br/~cz/aulas/Swarm.pdf